Lab08 Kaleo256333

Kaleo Campos

2026-10-13

```
import polars as pl

basics = pl.read_csv(
    "title.basics0.tsv.gz",
    separator="\t",
    null_values="\\N",
    quote_char=None,
    columns=["tconst", "titleType", "primaryTitle", "genres"]
).filter(pl.col("titleType") == "movie")

ratings = pl.read_csv(
    "title.ratings.tsv.gz",
    separator="\t",
    null_values="\\N"
)

filmes = basics.join(ratings, on="tconst", how="inner")
```

Questão 1

Quais são os 5 filmes com as maiores notas (`averageRating`)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
melhores_filmes = (
    filmes
    .sort(
        ["averageRating", "numVotes", "tconst"],
        descending=[True, True, False]
    )
    .select(["tconst", "primaryTitle", "averageRating", "numVotes"])
```

```
    .head(5)
)

melhores_filmes
```

shape: (5, 4)

tconst	primaryTitle	averageRating	numVotes
str	str	f64	i64
tt33075815	Kaveri	10.0	1023
tt27815015	Kurukku	10.0	451
tt28450376	Jedal Dar Omghe 30 Metri	10.0	142
tt27859713	Sargashte	10.0	134
tt33507675	Gorgeous Rascal	10.0	115

Questão 2

Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
frequencia_generos = (
    filmes
    .filter(pl.col("averageRating") > 8)
    .drop_nulls("genres")
    .with_columns(pl.col("genres").str.split(","))
    .explode("genres")
    .group_by("genres")
    .agg(pl.col("tconst").n_unique().alias("n_filmes"))
)

genero_mais_frequente = (
    frequencia_generos
    .filter(pl.col("n_filmes") == pl.col("n_filmes").max())
    .sort("genres")
)

genero_mais_frequente
```

```
shape: (1, 2)
┌─────────────┬──────────┐
│ genres      ┆ n_filmes │
│ ---         ┆ ---      │
│ str         ┆ u32      │
╞═════════════╪══════════╡
│ Documentary ┆ 10564    │
└─────────────┴──────────┘
```

Questão 3

Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
principals = pl.read_csv(
    "title.principals0.tsv.gz",
    separator="\t",
    null_values="\\N",
    quote_char=None,
    columns=["tconst", "nconst", "category"]
).filter(
    pl.col("category").is_in(["actor", "actress"])
).drop_nulls("nconst").select(["tconst", "nconst"])

atores = (
    principals
    .join(
        filmes.filter(pl.col("averageRating") > 7.5).select("tconst"),
        on="tconst", how="inner"
    )
    .group_by("nconst")
    .agg(pl.col("tconst").n_unique().alias("n_filmes"))
    .sort(["n_filmes", "nconst"], descending=[True, False])
    .head(3)
)
```

```
shape: (3, 2)
```

nconst	n_filmes
str	u32
nm0004660	199
nm0595934	155
nm3183374	124

Os arquivos identificam os atores/atrizes por `nconst` e não contêm seus nomes.

```
from datetime import datetime

print(datetime.now().astimezone())
```

```
2026-10-13 17:01:11.344149-03:00
```